Lec 2 - 回归模型与 OLS 估计

HenryY

Econ0004

2026 年 2 月 21 日

目录

课程导论与模型设定

普通最小二乘法 (OLS) 的推导

OLS 估计量的性质与假设

解释变量的对数变换

遗漏变量偏差 (Omitted Variable Bias) 分析

课程导论与模型设定

1.1 本次 Live Session 的目的

- **回顾与深化：** 总结预录课程视频的核心内容。
- **检验理解：** 通过问题测试对关键概念的理解程度。
- **数学推导跟进：** 详细展示预录视频中的数学推导过程。
- **重点推导：** 详细推导普通最小二乘法（Ordinary Least Squares, OLS）估计量。
- **对数变换解释：** 演示为什么在工资方程中使用 ln(wage) 可以解释为工资的百分比变化。
- **偏差分析应用：** 应用遗漏变量偏差（Omitted Variable Bias）框架分析具体问题。

- 我们关注的核心问题是：**教育如何影响工资？**
- 一个简单的经验模型可以设定为：

$$\text{wage} = \alpha + \beta \cdot \text{educ} + \epsilon$$

- 其中：
  - wage: 个体的工资（被解释变量，dependent variable）
  - educ: 个体的受教育年限（解释变量，independent variable）
  - α: 截距项（intercept），表示当 educ=0 时的平均工资。
  - β: 斜率系数（slope coefficient），表示多接受一年教育，工资的平均变化量。
  - ϵ: 误差项（error term），包含了除教育外所有影响工资的其他因素。
- 我们的目标是利用样本数据，找到 α 和 β 的“好”的估计量 $\hat{\alpha}$ 和 $\hat{\beta}$。

- 我们将模型一般化，并明确写出误差项：

$$y_i = \alpha + \beta x_i + \epsilon_i \quad (4)$$

- α 和 β 是未知的总体参数（population parameters），是我们试图“恢复”的真实值。
- 误差项 ϵ_i 的存在及其大小未知，使得我们无法精确计算 α 和 β。
- $\Rightarrow$ 我们只能通过样本数据来**估计 (estimate)** 它们，得到 $\hat{\alpha}$ 和 $\hat{\beta}$。
- **关键点：**我们对误差项 ϵ_i 所做的**假设 (assumptions)**，决定了所采用的估计技术（如 OLS）的性质（如无偏性、有效性）。

普通最小二乘法 (OLS) 的推导

2.1 OLS 的核心思想：最小化残差

- 对于任意一组估计值 $\hat{\alpha}$ 和 $\hat{\beta}$，我们可以计算每个观测的**残差 (residual)** $\hat{\epsilon}_i$:

$$\hat{\epsilon}_i = y_i - \hat{y}_i = y_i - (\hat{\alpha} + \hat{\beta} x_i)$$

- 残差代表了模型未能拟合的部分。一个“好”的估计量应该使这些残差“很小”。
- OLS 对“小”的定义是：**最小化残差平方和 (Sum of Squared Residuals)**。
- 因此，OLS 估计量 $\hat{\alpha}$ 和 $\hat{\beta}$ 是下面最小化问题的解：

$$Q = \sum_{i=1}^{n} \hat{\epsilon}_i^2 = \sum_{i=1}^{n} (y_i - \hat{\alpha} - \hat{\beta} x_i)^2 \quad (7)$$

- **简单示例：**假设只有两个点 (1,2) 和 (3,4)。如果猜测 $\hat{\alpha} = 1, \hat{\beta} = 1$，则 $Q = (2 - 1 - 1 * 1)^2 + (4 - 1 - 1 * 3)^2 = 0^2 + 0^2 = 0$。如果猜测 $\hat{\alpha} = 0, \hat{\beta} = 1$，则 $Q = (2 - 0 - 1)^2 + (4 - 0 - 3)^2 = 1^2 + 1^2 = 2$。OLS 的目标是找到使 Q 最小的那一组参数。

- 最小化 Q 是一个微积分问题。最优的 $\hat{\alpha}$ 和 $\hat{\beta}$ 必须满足一阶条件（First Order Conditions, FOCs）：Q 对 $\hat{\alpha}$ 和 $\hat{\beta}$ 的偏导数为零。
- 对 $\hat{\alpha}$ 求偏导：

$$\frac{\partial Q}{\partial \hat{\alpha}} = -2\sum_{i=1}^{n}(y_i - \hat{\alpha} - \hat{\beta}x_i) = 0 \quad (8)$$

- 对 $\hat{\beta}$ 求偏导：

$$\frac{\partial Q}{\partial \hat{\beta}} = -2\sum_{i=1}^{n}x_i(y_i - \hat{\alpha} - \hat{\beta}x_i) = 0 \quad (9)$$

- 这两个方程被称为**正规方程 (normal equations)**。它们是求解 $\hat{\alpha}$ 和 $\hat{\beta}$ 的基础。
- **板书提示：**展示对 $Q = \sum(y_i - \hat{\alpha} - \hat{\beta}x_i)^2$ 求偏导的详细步骤，强调链式法则。

- 将一阶条件中的求和符号展开，得到更便于使用的形式。
- 由 (8) 式可得：

$$\sum y_i - n\hat{\alpha} - \hat{\beta}\sum x_i = 0 \quad (8')$$

- 由 (9) 式可得：

$$\sum x_i y_i - \hat{\alpha}\sum x_i - \hat{\beta}\sum x_i^2 = 0 \quad (9')$$

- 这里，$\sum$ 均表示对 $i = 1$ 到 n 求和。n 是样本容量。
- 方程 (8') 和 (9') 组成了关于未知数 $\hat{\alpha}$ 和 $\hat{\beta}$ 的线性方程组。我们可以通过代入法求解。

2.4 推导截距项估计量 $\hat{\alpha}$

- 从正规方程 (8') 开始：

$$\sum y_i - n\hat{\alpha} - \hat{\beta}\sum x_i = 0$$

- 将包含 $\hat{\alpha}$ 的项移到等式右边：

$$n\hat{\alpha} = \sum y_i - \hat{\beta}\sum x_i$$

- 两边同时除以 n，得到 $\hat{\alpha}$ 的表达式：

$$\hat{\alpha} = \frac{\sum y_i}{n} - \hat{\beta}\frac{\sum x_i}{n}$$

- 注意到 $\bar{y} = \frac{\sum y_i}{n}$ 和 $\bar{x} = \frac{\sum x_i}{n}$，因此：

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \quad (10)$$

- **解释：** 这意味着 OLS 回归线必然经过样本均值点 $(\bar{x}, \bar{y})$。

2.5 推导斜率项估计量 $\hat{\beta}$

- 将 (10) 式 $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$ 代入正规方程 (9')：

$$\sum x_i y_i - (\bar{y} - \hat{\beta}\bar{x}) \sum x_i - \hat{\beta} \sum x_i^2 = 0$$

- 展开并整理包含 $\hat{\beta}$ 的项：

$$\sum x_i y_i - \bar{y} \sum x_i = \hat{\beta}(\sum x_i^2 - \bar{x} \sum x_i)$$

- 利用 $\sum x_i = n\bar{x}$ 和 $\bar{y} \sum x_i = n\bar{x}\bar{y}$，可得：

$$\sum x_i y_i - n\bar{x}\bar{y} = \hat{\beta}(\sum x_i^2 - n\bar{x}^2) \quad (12)$$

- 因此，斜率估计量 $\hat{\beta}$ 为：

$$\hat{\beta} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}$$

- 这等价于用离差形式表示的著名公式：

$$\hat{\beta} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} \quad (13)$$

- $\hat{\beta}$ 的另一种解释：它是 y 和 x 的**样本协方差 (sample covariance)** 与 x 的**样本方差 (sample variance)** 之比。

$$\hat{\beta} = \frac{\widehat{\mathrm{Cov}}(y, x)}{\widehat{\mathrm{Var}}(x)}$$

- $\hat{\beta}$ 的符号完全由 y 和 x 之间的样本相关系数决定。
- $\hat{\beta}$ 是一个**线性估计量 (linear estimator)**：它可以表示为 y_i 的加权和。
- 由 (10) 式可知，$\bar{y} = \hat{\alpha} + \hat{\beta}\bar{x}$，即拟合的回归线通过点 $(\bar{x}, \bar{y})$。
- 残差的均值 $\bar{\hat{\epsilon}}$ 必然为零。这是由一阶条件 (8) 直接推出的。

OLS 估计量的性质与假设

3.1 估计量的理想性质

- 我们如何评判一个估计量（如 $\hat{\beta}$）的好坏？主要有三个标准：
- **1. 无偏性 (Unbiasedness)：**
  - 定义：估计量的期望等于总体参数的真值。即 $E(\hat{\beta}) = \beta$。
  - 含义：在无数次重复抽样中，估计量的平均值会落在真实值上。没有系统性偏差。
- **2. 一致性 (Consistency)：**
  - 定义：随着样本量 n 趋向无穷大，估计量依概率收敛于总体参数的真值。
  - 含义：当样本量足够大时，估计值会非常接近真实值。即使估计量在小样本下有偏，也可能是一致的。
- **3. 有效性 (Efficiency)：**
  - 定义：在所有无偏估计量（或一类估计量）中，该估计量的方差最小。
  - 含义：估计量的抽样分布最集中，不确定性最小。
- OLS 估计量在特定假设下，能够拥有这些理想性质。

- 为了保证 OLS 估计量是**最佳线性无偏估计量 (Best Linear Unbiased Estimator, BLUE)**，我们需要满足高斯-马尔可夫定理的假设条件：
- **假设 1: 参数线性 (Linear in Parameters)** 模型为 $y = \alpha + \beta x + \epsilon$。
- **假设 2: 条件均值独立性 (Zero Conditional Mean)** $E(\epsilon|x) = 0$。这意味着解释变量 x 不包含任何可用于预测 ϵ 均值的信息。这是保证无偏性的关键。
- **假设 3: 同方差性 (Homoskedasticity)** $\mathrm{Var}(\epsilon|x) = \sigma^2$。即误差项的方差为常数，不随 x 变化。
- **假设 4: 无自相关 (No Autocorrelation)** $\mathrm{Cov}(\epsilon_i, \epsilon_j) = 0, \forall i \neq j$。不同观测的误差项之间不相关（对于横截面数据尤为重要）。
- 如果 A1-A4 成立，那么 OLS 估计量就是 BLUE——在所有线性无偏估计量中，它具有最小方差。

解释变量的对数变换

4.1 为什么使用对数工资 (ln wage)?

- 在实证研究中，我们经常看到模型使用 ln(wage) 而不是 wage 本身作为被解释变量。例如：

$$\ln(\text{wage}) = \alpha + \beta \cdot \text{educ} + \epsilon$$

- 这样做主要有两个原因：
  1. **经济含义：** ln(wage) 的微小变化可以近似解释为 wage 的**百分比变化 (percentage change)**。
  2. **统计性质：** 工资的分布通常是右偏的（少数人工资极高），取对数可以使分布更接近正态分布，减少异常值的影响，有助于满足同方差假设。
- 这种模型被称为**对数-水平值模型 (log-level model)**。

- **数学推导：**对于非常小的变化，有近似关系 $\ln(y+\Delta y)-\ln(y)\approx\frac{\Delta y}{y}$。即对数差分近似等于变量的**变化率 (rate of change)**。
- 在我们的模型 $\ln y=\alpha+\beta x$ 中，考虑 x 的一个单位变化（$\Delta x=1$）：

$$\Delta\ln y=\ln(y_1)-\ln(y_0)=[\alpha+\beta(x_0+1)]-[\alpha+\beta x_0]=\beta$$

- 因此，$\beta=\Delta\ln y\approx\frac{\Delta y}{y_0}$。这意味着 β 衡量了当 x 增加一个单位时，y 的**近似百分比变化**。
- **简单示例：**假设估计结果为 $\ln(\widehat{wage})=1.5+0.08\times educ$。那么：
  - 当教育年限从 12 年增加到 13 年时，$\Delta\ln(wage)=0.08$。
  - 这意味着工资预计会**增加约 8%**。精确计算是 $\frac{\Delta wage}{wage}\approx 0.08$。
- 因此，我们可以将 β 解释为“多接受一年教育所带来的工资的**预期百分比变化**”。

遗漏变量偏差 (Omitted Variable Bias) 分析

5.1 应用实例：出勤率对成绩的影响

- **研究问题：**讲座出勤率（attend）对期末成绩（Ingrade）的影响。
- 你首先运行了一个简单回归，得到：

$$\widehat{\ln grade} = 1.52 + 0.05 \times attend \quad (R1)$$

- **担忧：**估计值 $\hat{\beta}_{attend} = 0.05$ 可能存在偏差，因为模型中遗漏了一个重要变量：每周学习小时数（study hours）。
- 学习时长很可能同时与两个变量相关：
  - 与 **attend** 相关：努力学习的学生可能既去上课，也花更多时间自习（正相关）。
  - 与 **Ingrade** 相关：学习时间越长，成绩通常越好（正相关）。
- 这种情形是典型的**遗漏变量偏差 (Omitted Variable Bias, OVB)**。

- **真实模型 (True Model):**

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u \quad (1)$$

其中 $y = \ln grade$, $x_1 = attend$, $x_2 = study\ hours$。

- **估计模型 (Estimated Model):**

$$y = \beta_0 + \beta_1 x_1 + \nu \quad (2)$$

这里我们遗漏了 x_2，所以误差项 $\nu = \beta_2 x_2 + u$。

- 我们关心的是，用模型 (2) 估计出的 $\hat{\beta}_1$ 的期望值 $E(\hat{\beta}_1)$ 是多少?
- 我们知道 $\hat{\beta}_1$ 的公式是 $\frac{\mathrm{Cov}(y,x_1)}{\mathrm{Var}(x_1)}$。将真实模型 (1) 代入:

$$\hat{\beta}_1 = \frac{\mathrm{Cov}(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + u, x_1)}{\mathrm{Var}(x_1)}$$

5.3 遗漏变量偏差的正式推导（二）

- 利用协方差的性质展开分子：

$$\hat{\beta}_1 = \frac{\mathrm{Cov}(\beta_0, x_1) + \beta_1 \mathrm{Cov}(x_1, x_1) + \beta_2 \mathrm{Cov}(x_2, x_1) + \mathrm{Cov}(u, x_1)}{\mathrm{Var}(x_1)}$$

- 假设真实模型正确设定，则 $\mathrm{Cov}(\beta_0, x_1) = 0$，且 $E[\mathrm{Cov}(u, x_1)] = 0$。因此，取期望后：

$$E(\hat{\beta}_1) = \beta_1 + \beta_2 \frac{\mathrm{Cov}(x_2, x_1)}{\mathrm{Var}(x_1)}$$

- 因此，偏差 $= E(\hat{\beta}_1) - \beta_1$ 为：

$$\mathrm{Bias}(\hat{\beta}_1) = \beta_2 \frac{\mathrm{Cov}(x_2, x_1)}{\mathrm{Var}(x_1)}$$

- 这个公式告诉我们，偏差的方向和大小取决于两个因素：
  1. 遗漏变量 x_2 对 y 的偏效应 β_2。
  2. 遗漏变量 x_2 与包含的解释变量 x_1 之间的相关性 $\mathrm{Cov}(x_2, x_1)$。

5.4 偏差的方向判定表

- 根据公式 $\text{Bias}(\hat{\beta}_1) \propto \beta_2 \times \text{Cov}(x_2, x_1)$，我们可以总结出偏差方向的判定法则。

	$\text{Cov}(x_2, x_1) > 0$	$\text{Cov}(x_2, x_1) < 0$
$\beta_2 > 0$	**正偏 (Positive Bias)**	负偏 (Negative Bias)
$\beta_2 < 0$	负偏 (Negative Bias)	**正偏 (Positive Bias)**

- **应用到期初的例子上：**
  - β_2 (学习时长的效应) 预计为正。
  - $\text{Cov}(x_2, x_1)$ (学习时长与出勤率的相关性) 预计为正。
- **结论：**根据判定表，$\hat{\beta}_{attend}$ 会有一个**正偏 (positive bias)**。这意味着在简单回归 (R1) 中，我们估计出的 0.05 高估了出勤率对成绩的真实因果效应。

5.5 回到实例：解读回归结果

- 你将每周学习小时数加入回归后，得到新的结果：

$$\widehat{\ln grade} = 1.52 + 0.03 \times attend + 0.08 \times weeklyhours \quad (R2)$$

- **问题：**结果是否表明样本中 weekly hours 与 attend 负相关或正相关？为什么？
- **分析：**
  1. 在 (R1) 中，$\hat{\beta}_{attend} = 0.05$ (有偏估计)。
  2. 在 (R2) 中，控制了 weekly hours 后，$\hat{\beta}_{attend}$ 下降到了 0.03。这被认为是更接近真实效应 β_1 的一致估计。
  3. 根据 OVB 公式，从 0.05 下降到 0.03 意味着原来的偏差是正的。
  4. 我们知道 $\hat{\beta}_2 = 0.08 > 0$ (学习时间对成绩有正影响)。
  5. 为了让偏差为正 $(0.05 - 0.03 = 0.02 > 0)$，根据公式 $\text{Bias} = \beta_2 \times \frac{\text{Cov}(x_2, x_1)}{\text{Var}(x_1)}$，必须有 $\text{Cov}(x_2, x_1) > 0$。
- **结论：**因此，结果（$\hat{\beta}_{attend}$ 下降）表明在样本中，weekly hours 与 attend 是**正相关的**。这符合直觉：更用功的学生两者都高。

- **本节课核心内容回顾：**
  - 我们详细推导了简单线性回归模型的 OLS 估计量。
  - 讨论了 OLS 估计量的代数性质和统计性质（无偏性、一致性、有效性）。
  - 学习了高斯-马尔可夫定理及其所需的基本假设。
  - 解释了为何使用对数形式的被解释变量，以及如何解释其系数。
  - 深入分析了遗漏变量偏差的来源、方向判定及其在实际例子中的应用。
- **下节课预告 (Lecture 3)：**我们将在此基础上，进一步探讨：
  - OLS 估计量方差的推导。
  - 如何进行统计推断（Hypothesis Testing），例如检验某个系数是否显著不为零。
  - 介绍 t-统计量和 F-统计量的构建与使用。
- **思考题：**如果遗漏变量与包含变量不相关，OLS 估计量还会是有偏的吗？