Lec 3 - 拟合优度与假设检验

HenryY

Econ0004

2026 年 2 月 24 日

目录

拟合优度指标

参数估计量的标准误

假设检验基础

应用案例与 Python 实践

拟合优度指标

- OLS 估计量 $\hat{\alpha}$ 和 $\hat{\beta}$ 通过最小化残差平方和（Residual Sum of Squares, RSS）得到：

$$RSS = \sum_{i=1}^{N} \hat{\epsilon}_i^2 = \sum_{i=1}^{N} (y_i - \hat{\alpha} - \hat{\beta} x_i)^2$$

- 回归方程的标准误（Standard Error of the Equation, SEE）是误差项 ϵ_i 的标准差的估计值。它衡量了残差的波动程度。
- 计算公式为：

$$SEE = \sqrt{\frac{RSS}{N-K}}$$

  其中，N 是样本量，K 是模型中待估参数的个数（在简单线性回归中 $K = 2$）。
- **数值示例：** 假设有一个简单线性回归模型，样本量 $N = 100$，计算得到的 $RSS = 200$。则：

$$SEE = \sqrt{\frac{200}{100-2}} = \sqrt{\frac{200}{98}} \approx \sqrt{2.0408} \approx 1.43$$

- SEE 的单位与因变量 y 的单位相同。

- R^2，又称决定系数（Coefficient of Determination），是衡量模型拟合优度的标准化指标。
- 它度量了因变量 y_i 的总变异中，能被模型解释的部分所占的比例。
- 计算公式基于平方和分解：

$$\text{总平方和 (Total Sum of Squares, TSS)} = \sum_i (y_i - \bar{y})^2$$

$$\text{解释平方和 (Explained Sum of Squares, ESS)} = \sum_i (\hat{y}_i - \bar{y})^2$$

$$\text{残差平方和 (Residual Sum of Squares, RSS)} = \sum_i (y_i - \hat{y}_i)^2$$

- 三者关系：TSS = ESS + RSS。
- R^2 的定义为：

$$R^2 = 1 - \frac{RSS}{TSS} = \frac{ESS}{TSS}$$

- **数值示例：** 沿用前例，若 $TSS = 500$，$RSS = 200$，则：

1.3 R^2 的性质与解读

- R^2 的取值范围是 $[0, 1]$。
  - 当 $R^2 = 1$ 时，表示模型完美拟合所有数据点，所有残差为 0。
  - 当 $R^2 = 0$ 时，表示模型完全没有解释力，相当于只用均值 $\bar{y}$ 进行预测。
- R^2 是样本方差（或总变异）中被解释的比例：

$$R^2 = \frac{\frac{1}{N-1}\sum(\hat{y}_i - \bar{y})^2}{\frac{1}{N-1}\sum(y_i - \bar{y})^2} = \frac{\text{样本方差解释部分}}{\text{样本方差总部分}}$$

- **重要解读：**
  - 高的 R^2 不一定意味着模型是“好”的（可能存在过度拟合），低的 R^2 也不一定意味着模型无用。
  - R^2 衡量的是线性拟合的程度，不涉及因果关系的判断。
  - 在简单线性回归中，R^2 等于 x 与 y 之间相关系数 ρ_{xy} 的平方。
- **示例：** 若 $R^2 = 0.045$，意味着模型只解释了因变量变异的 4.5

参数估计量的标准误

- 我们通过 OLS 得到的系数估计量 $\hat{\beta}$ 是一个随机变量，它因样本的不同而不同。
- 标准误（Standard Error, SE）是衡量估计量 $\hat{\beta}$ 抽样波动大小的统计量。它本质上就是 $\hat{\beta}$ 的样本分布的标准差（Standard Deviation）的估计值。
- 公式上，$se(\hat{\beta})$ 是 $\hat{\beta}$ 的标准差 $\sigma_{\hat{\beta}}$ 的估计值。
- **关键区别：**
  - 标准差（Standard Deviation）：描述原始数据点相对于其均值的离散程度。
  - 标准误（Standard Error）：描述一个统计量（如均值、回归系数）在重复抽样中可能的变化范围，即估计量的精度。
- 一个较小的标准误意味着 $\hat{\beta}$ 的估计更精确，更接近真实的总体参数 β。

- 要估计 $se(\hat{\beta})$，我们需要知道两个关键量：
  1. 误差项 ϵ_i 的波动程度：我们用 SEE 来估计，即 $\hat{\sigma} = SEE$。
  2. 解释变量 x_i 的样本变异程度：用 x 的样本方差 s_x^2 或样本标准差 s_x 来衡量。
- 在满足经典假设（A1-A4）的条件下，$\hat{\beta}$ 的方差公式为：

$$\mathrm{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum_{i=1}^{N}(x_i - \bar{x})^2}$$

  其中，σ^2 是误差项的方差。
- 因此，$\hat{\beta}$ 的标准误估计量为：

$$se(\hat{\beta}) = \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^{N}(x_i - \bar{x})^2}} = \frac{SEE}{\sqrt{\sum_{i=1}^{N}(x_i - \bar{x})^2}}$$

- **示例：** 假设 $SEE = 1.43$，且 $\sum(x_i - \bar{x})^2 = 1000$，则：

$$se(\hat{\beta}) = \frac{1.43}{\sqrt{1000}} \approx \frac{1.43}{31.62} \approx 0.045$$

- 从公式 $se(\hat{\beta}) = \frac{SEE}{\sqrt{\sum(x_i-\bar{x})^2}}$ 可以直观看到标准误受两个因素影响：
- **因素 1：误差项的波动性（SEE）**
  - 误差项波动越大，数据点围绕回归线的离散程度越大，我们对系数估计的信心就越低。
  - **关系：** SEE 越大，$se(\hat{\beta})$ 越大，估计精度越低。
- **因素 2：解释变量的变异程度（$\sum(x_i - \bar{x})^2$）**
  - 如果 x 的取值非常集中，我们就很难准确估计出 x 变化一个单位对 y 的影响。如果 x 的取值分散，信息量更大，估计就更精确。
  - **关系：** x 的变异越大，分母越大，$se(\hat{\beta})$ 越小，估计精度越高。
- **直观示例：** 想估计教育对工资的影响。如果你只观测到大学毕业生（x 变异小），你很难知道高中和大学的工资差；如果你观测了从小学到博士的人群（x 变异大），你就能更精确地估计出教育的回报率。

假设检验基础

- 在计量经济学中，我们通常只有来自总体（Population）的一个样本。OLS 估计量 $\hat{\beta}$ 是总体真实参数 β 的一个估计。
- 假设检验（Hypothesis Testing）是一种统计推断方法，它允许我们根据样本数据，对关于总体参数 β 的某个主张（假设）做出接受或拒绝的判断。
- **核心逻辑：**
  1. 提出一个关于总体参数的假设，称为原假设（Null Hypothesis, H_0）。通常是我们想要挑战的观点，例如“教育对工资没有影响”（$\beta = 0$）。
  2. 提出与原假设对立的备择假设（Alternative Hypothesis, H_1）。
  3. 构造一个检验统计量（Test Statistic），它在原假设成立时的抽样分布是已知的。
  4. 计算该统计量在样本中的具体数值，以及对应的概率值（p 值）。p 值表示在原假设为真的情况下，观察到当前样本结果（或更极端结果）的概率。
  5. 如果 p 值很小（小于预先设定的显著性水平，如 5

- 根据备择假设 H_1 的方向，检验可以分为单侧和双侧。
- **双侧检验（Two-sided Test）：** 备择假设关注参数是否“不等于”原假设的值，不考虑方向。

$$H_0 : \beta = \beta_0 \quad \text{vs} \quad H_1 : \beta \neq \beta_0$$

  例如，检验教育对工资的影响是否显著不为 0。
- **单侧检验（One-sided Test）：** 备择假设关注参数是否“大于”或“小于”原假设的值，具有方向性。

$$H_0 : \beta \geq \beta_0 \quad \text{vs} \quad H_1 : \beta < \beta_0$$

  或者

$$H_0 : \beta \leq \beta_0 \quad \text{vs} \quad H_1 : \beta > \beta_0$$

  例如，检验广告策略是否有效提高了流感疫苗接种率（$p > p_0$）。
- **注意：** 检验的“单侧”或“双侧”由备择假设决定。例如，即使原假设是 $\beta = 0$，如果备择是 $\beta < 0$，这仍是一个单侧检验。

- 在回归分析中，最常用的检验是关于某个系数是否为 0 的原假设：$H_0 : \beta_j = 0$。这个假设在经济学中通常意味着“变量 x_j 对 y 没有影响”。
- 用于检验该假设的统计量是 t 统计量（t-statistic）或 t 比率（t-ratio）：

$$t = \frac{\hat{\beta}_j}{se(\hat{\beta}_j)}$$

- 这个 t 统计量测量了估计值 $\hat{\beta}_j$ 距离 0 有多少个标准误。
- **判断规则：**
  - 如果 $|t|$ 很大（通常大于 2），说明 $\hat{\beta}_j$ 显著偏离 0，我们有足够证据拒绝原假设，认为 x_j 对 y 有显著影响。
  - 回归软件包通常会直接报告这个 t 值以及对应的 p 值。
- **数值示例：** 若 $\hat{\beta} = 0.0658$，$se(\hat{\beta}) = 0.0041$，则：

$$t = \frac{0.0658}{0.0041} \approx 16.05$$

这个 t 值远大于 2，因此我们拒绝“教育对工资无影响”的原假设。

3.4 置信区间的构建与解释

- 置信区间（Confidence Interval）是另一个重要的推断工具。它提供了一个围绕点估计的区间，该区间以一定的置信水平包含总体真实参数。
- 一个 $(1-\alpha)\times 100\%$ 的置信区间是所有无法被显著性水平为 α 的 t 检验拒绝的 β 值构成的集合。
- 对于系数 β，其置信区间基于 t 统计量的抽样分布构建：

$$\hat{\beta} \pm t_{N-K,\alpha/2} \times se(\hat{\beta})$$

  其中，$t_{N-K,\alpha/2}$ 是自由度为 $N-K$ 的 t 分布的临界值。
- 对于大样本（如 $N>30$），$t_{N-K,\alpha/2}$ 近似于正态分布的临界值 $z_{\alpha/2}$。
- **95% 置信区间（大样本近似）：**

$$[\hat{\beta} - 1.96 \times se(\hat{\beta}), \quad \hat{\beta} + 1.96 \times se(\hat{\beta})]$$

- **解释：**如果我们重复抽样 100 次并构建 100 个这样的区间，大约有 95 个区间会包含真实的总体参数 β。
- **数值示例：**若 $\hat{\beta} = 0.0658$，$se(\hat{\beta}) = 0.0041$，则 95% 置信区间为：

$$0.0658 \pm 1.96 \times 0.0041 = 0.0658 \pm 0.008036 = [0.0578, 0.0738]$$

应用案例与 Python 实践

- **问题：**如果解释平方和（ESS）是 35，总平方和（TSS）是 49，那么残差平方和（RSS）是多少?
- 选项：A. 10 B. 14 C. 84
- **解析：**
  - 根据平方和分解公式：$\text{TSS} = \text{ESS} + \text{RSS}$
  - 因此，$\text{RSS} = \text{TSS} - \text{ESS}$
  - 代入数值：$\text{RSS} = 49 - 35 = 14$
- **答案：B. 14**
- **板书演示：**

$$\text{总变异} = \text{模型解释的变异} + \text{未被解释的变异}$$

$$49 = 35 + 14$$

4.2 理解测试：R^2 的含义

- **问题：** 下列关于 R^2 的说法，哪一项是正确的？
  1. R^2 也被称为回归的标准误。
  2. 低的 R^2 表明 OLS 线很好地拟合了数据。
  3. R^2 显示了因变量 Y 的总变异中有多大百分比被解释变量所解释。
- **解析：**
  - 选项 1 错误：回归的标准误是 SEE，不是 R^2。
  - 选项 2 错误：低的 R^2 意味着模型拟合不佳，大部分变异未被解释。
  - 选项 3 正确：这正是 R^2 的定义，它衡量的是模型解释的变异比例。
- **答案：选项 3**

- **问题：** 通用的 t 统计量可以写成以下哪种形式？
  1. $t = \frac{\text{假设值}}{\text{标准误}}$
  2. $t = \frac{\text{估计值}-\text{假设值}}{\text{标准误}}$
  3. $t = \frac{\text{估计值}-\text{假设值}}{\text{方差}}$
- **解析：**
  - t 统计量的一般形式是“（估计值 - 假设的总体值）除以估计量的标准误”。
  - 对于常见的检验 $H_0 : \beta = 0$，公式简化为 $\frac{\hat{\beta}}{se(\hat{\beta})}$。
  - 分母必须是标准误，而不是方差（方差是标准误的平方）。
- **答案：选项 2**
- **板书：**

$$t = \frac{\text{估计量} - \text{原假设下的参数值}}{\text{估计量的标准误}}$$

4.4 应用案例：学校规模对学生成绩的影响

- **研究问题：**学生是否在规模较小的学校表现更好？
- **数据：** 2013 年密歇根州 500 所高中的数据。
- **变量：**
  - $math10$：通过标准化数学考试的学生百分比。
  - $enroll$：学校注册学生数。
- **估计结果（标准误在括号中）：**

$$\widehat{math10} = 3.274 - 0.00020 \times enroll$$

$$(6.113) \quad (0.00022)$$

- $N = 500$，$R^2 = 0.045$
- **初步解读：**
  - 系数为负 (-0.00020)，表明学校规模越大，通过率似乎越低，符合直觉。
  - 但标准误 (0.00022) 与系数本身大小相当。

4.5 应用案例：租金与学生比例的关系

- **研究问题：** 大学城的学生比例是否会影响租金？
- **数据：** 2015 年 64 个大学城的数据。
- **变量：**
  - $\log(rent)$：平均月租金的对数。
  - $pctstu$：学生人口占总人口的比例。
- **估计结果（标准误在括号中）：**

$$\widehat{\log(rent)} = 0.043 + 0.056 \times pctstu$$

$$(0.844) \quad (0.0017)$$

- **初步解读：**
  - 系数为正 (0.056)，表明学生比例越高的城镇，租金水平越高。
  - 标准误 (0.0017) 相对于系数非常小，说明估计很精确。
  - 注意因变量是对数形式，系数需要特殊解释（百分比变化）。

4.6 Python 实践：模型解读 (ln wage on edu)

- 我们运行了以下回归模型：$\ln(wage) = \alpha + \beta \cdot education + \epsilon$
- **Python 输出摘要：**

Dep. Variable:	lnw
R-squared:	0.123
Model:	OLS
Method:	Least Squares
No. Observations:	1822
DF Residuals:	1820
DF Model:	1

	coef	**std err**	**t**	**P>|t|**	**[0.025**	**0.975]**
Intercept	0.8943	0.0771	11.632	0.000	0.743	1.045
edu	0.0658	0.0041	15.988	0.000	0.058	0.074

- **常数项 $\hat{\alpha}$ 的估计值是多少？**
  - 从输出中，$\hat{\alpha} = 0.8943$。
  - **解释：** 常数项衡量的是，当解释变量 $education = 0$ 时，因变量 $\ln(wage)$ 的预测值。具体来说，它代表了一个没有受过任何正式教育的人，其对数工资的期望值。在现实背景中，这可能是一个截距项，不一定有直观的经济含义，但它在数学上保证了回归线的位置。
- **参数 $\hat{\beta}$ 的估计值是多少？如何解释？**
  - $\hat{\beta} = 0.0658$。
  - **解释：** 在 $\ln(wage)$ 对 $education$ 的回归中，系数 β 表示教育年限每增加一年，工资所增加的百分比（近似）。因此，$\hat{\beta} = 0.0658$ 意味着，在其他条件不变的情况下，多接受一年教育，平均工资预期会增长约 6.58%。
  - 这是一个半弹性（semi-elasticity）的解释。

- **参数估计量 $\hat{\alpha}$ 和 $\hat{\beta}$ 的标准误是多少？**
  - $se(\hat{\alpha}) = 0.0771$
  - $se(\hat{\beta}) = 0.0041$
- **标准误如何依赖于 a) 教育年限的方差和 b) 误差的波动性？**
  - **与教育年限方差的关系：**公式 $se(\hat{\beta}) = SEE/\sqrt{\sum(edu_i - \overline{edu})^2}$ 显示，$\hat{\beta}$ 的标准误与教育年限的变异程度的平方根成反比。如果样本中教育年限非常分散（方差大），则标准误较小，估计更精确。反之，如果教育年限集中，标准误会较大。
  - **与误差波动性的关系：**标准误与 SEE 成正比。SEE 是误差项标准差的估计，它度量了工资中无法被教育解释的部分的波动性。如果工资中不可解释的部分波动很大（例如，受很多其他因素影响），那么我们对教育回报率的估计就会更不精确，标准误也更大。

- **原假设与备择假设：**

$$H_0 : \beta = 0 \quad (\text{教育对工资无影响})$$

$$H_1 : \beta \neq 0 \quad (\text{教育对工资有影响})$$

- **检验统计量：** t 统计量已在输出中给出：

$$t = \frac{\hat{\beta}}{se(\hat{\beta})} = \frac{0.0658}{0.0041} \approx 16.05$$

- **p 值：** 输出中显示 $P > |t| = 0.000$。这意味着 p 值小于 0.001。
- **结论：**
  - 通常我们选择显著性水平 $\alpha = 0.05$。
  - 由于 p 值（< 0.001）远小于 0.05，我们拒绝原假设。
  - 因此，样本提供了非常强有力的统计证据，表明教育对工资有显著的正向影响。
- **板书：** 拒绝 H_0，支持 H_1。

- **问题：**教育的回报率（β）的 95% 置信区间是多少？
- **方法 1：直接从输出读取** Python 输出已经提供了基于精确 t 分布计算的置信区间：$[0.058, 0.074]$。
- **方法 2：使用大样本近似计算**对于大样本（N=1822），可以用正态近似：

$$\hat{\beta} \pm 1.96 \times se(\hat{\beta}) = 0.0658 \pm 1.96 \times 0.0041$$

- 计算边际误差（Margin of Error）：

$$1.96 \times 0.0041 = 0.008036$$

- 因此，近似 95% 置信区间为：

$$[0.0658 - 0.00804,\ 0.0658 + 0.00804] = [0.0578,\ 0.0738]$$

- 这与输出中给出的 $[0.058, 0.074]$ 非常接近，由于输出可能使用了更精确的 t 临界值。
- **解释：**我们有 95% 的把握认为，总体中每增加一年教育，工资的真实增长率在 5.78% 到 7.38% 之间。这个区间完全在 0 以上，再次证实了教育的显著正效应。

4.11 Python 实践：R^2 的解读

- **问题：**什么是 R^2？本次回归的 R^2 是多少？
- **定义回顾：** R^2 是决定系数，衡量了因变量的总变异中，能够被回归模型（即解释变量）解释的比例。
- 公式：

$$R^2 = 1 - \frac{RSS}{TSS} = \frac{ESS}{TSS}$$

- **本次回归的 R^2：**从输出中看到，$R^2 = 0.123$。
- **解读：**
  - 这意味着，在工资对数 ($\ln wage$) 的变异中，大约 12.3% 可以被教育年限这个变量所解释。
  - 剩余的 87.7% 的变异则来自于模型之外的误差项（即其他未包括在模型中的因素，如工作经验、能力、行业等）。
  - 这个 R^2 值相对较低，这在横截面数据分析中很常见，尤其是当因变量是个体层面的工资时，因为影响工资的因素非常多，仅靠教育一个变量很难解释全部。

4.12 总结与下讲预告

- **本节课核心内容回顾：**
  - 我们学习了衡量模型拟合优度的两个关键指标：SEE 和 R^2。
  - 深入理解了参数估计量的标准误，它衡量了估计的精度，并受到误差波动性和解释变量变异性的影响。
  - 掌握了假设检验的基本框架，包括原假设、备择假设、t 统计量、p 值以及如何根据它们做出统计推断。
  - 学会了如何构建和解释回归系数的置信区间。
  - 通过实际案例和 Python 输出，实践了如何解读回归结果，并进行假设检验。
- **下讲预告：**
  - Lecture 4: 我们将把简单线性回归扩展到多元回归（Multiple Regression），探讨当模型中有多个解释变量时，如何处理函数形式问题（functional form issues），例如非线性关系、交互项等。
  - 我们将学习如何控制其他变量，更干净地识别出我们感兴趣的因果效应。
- **课后练习：**尝试自己用 Python 运行一个简单线性回归，并对输出结果进行完整的解读，包括系数、标准误、t 值、p 值、置信区间和 R^2。