面板数据模型

EC902

HenryY

华威大学

2026 年 4 月 8 日

目录

1. 面板数据导论
2. 池回归模型与个体效应
3. 固定效应模型
4. 随机效应模型与 FE vs RE
5. 动态面板数据与应用

1.1 面板数据的定义与结构

- **面板数据（Panel Data）**是对同一组个体（$i = 1, \ldots, N$）在不同时间点（$t = 1, \ldots, T$）的重复观测。
- 数据结构：$y_{it}, \mathbf{x}_{it}$，其中 i 表示个体（公司、国家、个人），t 表示时期。
- 平衡面板（Balanced Panel）：所有个体在每一时期均有观测值；非平衡面板（Unbalanced Panel）则存在缺失。
- 模型一般形式：

$$y_{it} = \alpha_{it} + \mathbf{x}_{it}'\beta_{it} + u_{it}$$

需要施加约束才能估计。

1.2 面板数据的主要优势

- **控制个体异质性（Heterogeneity）**：允许每个个体拥有不同的截距项 α_i，捕捉不随时间变化的遗漏变量。
- **提供更多信息**：增加样本量，降低多重共线性，提高估计效率。
- **研究动态调整**：如滞后因变量模型，分析状态依赖。
- **识别因果效应**：通过固定效应消除时间不变的混淆因素。
- **微观与宏观结合**：既能分析个体行为，也能控制时间趋势。

1.3 示例 1：生产函数中的企业异质性

- 企业 i 的生产函数：$Q_i = A_i \cdot (L_i)^{\phi_1} \cdot \exp(v_i)$，$0 < \phi_1 < 1$。
- 对数化并引入时间维度：

$$\log(Q_{it}) = \phi_0 + \phi_1 \log(L_{it}) + u_i + v_{it}$$

  其中 $u_i = \log(A_i) - E[\log(A_i)]$，$\phi_0 = E[\log(A_i)]$。
- u_i 是企业效率（对计量者不可观测，但企业自知），v_{it} 是技术冲击（双方均未知）。
- **内生性**：$\log(L_{it})$ 与 u_i 正相关（高效企业雇佣更多劳动），OLS 估计 ϕ_1 有偏且不一致。

数值示例：假设真实 $\phi_1 = 0.5$，但 u_i 与 $\log(L_i)$ 相关系数 0.8，OLS 估计值可能高达 0.7，高估劳动产出弹性。

1.4 示例 2：项目评估与自选择问题

- 研究职业培训对工资的影响：

$$\log(wage_{it}) = \theta_t + \mathbf{z}_{it}'\gamma + \delta_1 prog_{it} + c_i + u_{it}$$

- $prog_{it}$：是否参加培训（$t = 1$ 时全为 0，$t = 2$ 时部分个体参与）。
- c_i：个体能力（不可观测），可能与 $prog_{it}$ 相关（能力强的人更可能参加培训）。
- **自选择偏误（Self-selection bias）**：若忽略 c_i，OLS 会高估培训效果。
- 面板数据可通过固定效应消除 c_i，得到无偏的 δ_1。

数值示例：假设真实培训效应 $\delta_1 = 0.1$，但参与培训者的平均能力 c_i 比未参与者高 0.3，OLS 估计的 δ_1 可能达到 0.4，严重夸大。

2.1 池回归模型（Pooled OLS）

- 最严格的设定：所有个体和时期具有相同的截距和斜率。

$$y_{it} = \alpha + \mathbf{x}_{it}'\beta + u_{it}$$

- 假设 $E(\mathbf{x}_{it}u_{it}) = 0$（外生性）。
- 当 $N \to \infty$ 或 $T \to \infty$ 时，OLS 一致。
- 缺点：完全忽略个体异质性，若真实存在 α_i，则 β 估计有偏。
- 常用于初步分析或作为比较基准。

数值示例：用 100 家公司 10 年数据估计 $\log(Q_{it}) = \alpha + 0.4\log(L_{it}) + u_{it}$，但真实 u_i 与 $\log(L_i)$ 相关，OLS 估计可能得到 0.6。

2.2 池回归的假设与一致性条件

- **强外生性（Strong exogeneity）**：$E(u_{it}|\mathbf{x}_{i1},\ldots,\mathbf{x}_{iT})=0$，对所有 t 成立。
- **同方差（Homoskedasticity）**：$Var(u_{it})=\sigma^2$。
- **无自相关（No autocorrelation）**：$Cov(u_{it},u_{is})=0$，$t\neq s$。
- 若 u_{it} 包含个体效应 c_i，则 $Cov(\mathbf{x}_{it},c_i)\neq 0$ 导致 OLS 不一致。
- 聚类稳健标准误（Cluster-robust SE）可缓解组内相关，但不解决偏误。

数值示例：模拟数据 $y_{it}=2+0.5x_{it}+c_i+\epsilon_{it}$，$c_i$ 与 x_{it} 相关 0.6，OLS 估计 $\hat{\beta}=0.78$，远大于真实值。

2.3 个体与时间虚拟变量模型

- 允许截距随个体和时间变化，但斜率不变：

$$y_{it} = \alpha_i + \gamma_t + \mathbf{x}_{it}'\beta + u_{it}$$

- 等价于加入 N 个个体虚拟变量和 $T-1$ 个时间虚拟变量：

$$y_{it} = \sum_{j=1}^{N} \alpha_j d_{j,it} + \sum_{s=2}^{T} \gamma_s d_{s,it} + \mathbf{x}_{it}'\beta + u_{it}$$

- 模型不含截距项（避免完全共线性）。
- 仍可通过 OLS 估计，但需注意虚拟变量数量。

数值示例：$N=3, T=3$，共 9 个观测值。加入 3 个个体哑元和 2 个时间哑元（$t=2,3$），直接回归得到 β 估计。

2.4 虚拟变量模型的估计与解释

- 若 N 较小，可直接使用 LSDV（Least Squares Dummy Variables）方法。
- 若 N 很大（如微观面板），计算机内存可能不足，需使用离差变换（见 Section 3）。
- 系数 β 的解释：在控制个体固定效应和时间固定效应后，$\mathbf{x}_{it}$ 对 y_{it} 的边际效应。
- α_i 反映个体 i 与基准个体的平均差异；γ_t 反映时期 t 相对于基期的平均影响。
- 时间固定效应可控制宏观经济冲击等共同因素。

数值示例：估计教育回报率，控制个体哑元（即个体固定效应）后，$\beta = 0.08$，表示教育年数每增加一年，工资平均增长 8%（净除个体能力差异）。

3.1 固定效应模型设定与严格外生性

- 个体效应模型：$y_{it} = \alpha_i + \mathbf{x}_{it}'\beta + u_{it}$，$u_{it} \sim iid(0, \sigma_u^2)$。
- **固定效应（FE）**将 α_i 视为与 $\mathbf{x}_{it}$ 可能相关的未观测随机变量。
- **严格外生性（Strict exogeneity）**：

$$E(u_{it}|\alpha_i, \mathbf{x}_{i1}, \ldots, \mathbf{x}_{iT}) = 0, \quad t = 1, \ldots, T$$

- 严格外生性排除了滞后因变量和同期内生变量。
- FE 能一致估计 β（仅限时变变量），但无法估计 α_i。

数值示例：$T = 2$，x_{it} 在个体内变化，严格外生意味着 u_{i1} 与 x_{i1}, x_{i2} 均不相关。

3.2 离差变换（Within Estimator）推导

- 对每个个体计算时间均值：$\bar{y}_i = \frac{1}{T}\sum_{t=1}^{T} y_{it}$，$\bar{\mathbf{x}}_i$ 类似。
- 原方程减去均值方程：

$$y_{it} - \bar{y}_i = (\mathbf{x}_{it} - \bar{\mathbf{x}}_i)'\beta + (u_{it} - \bar{u}_i)$$

- α_i 被消去。
- OLS 估计上述离差模型得到 $\hat{\beta}_{FE}$，称为组内估计量。
- 若 $T = 2$，离差等价于一阶差分（但一般 $T > 2$ 时更有效）。

数值示例：个体 i 有 $t = 1, 2$：$y_{i1} = 3, y_{i2} = 5$；$x_{i1} = 1, x_{i2} = 2$。则 $\bar{y}_i = 4, \bar{x}_i = 1.5$，离差后 $(y_{i1} - \bar{y}_i) = -1$，$(x_{i1} - \bar{x}_i) = -0.5$；$(y_{i2} - \bar{y}_i) = 1$，$(x_{i2} - \bar{x}_i) = 0.5$。回归通过原点得 $\hat{\beta} = 2$。

3.3 Within Estimator 数值示例

- 假设 $N=2, T=3$，数据如下：

i	t	y_{it}	x_{it}	$\bar{y}_i$	$\bar{x}_i$	$y_{it}-\bar{y}_i$	$x_{it}-\bar{x}_i$
1	1	4	1	5	2	-1	-1
1	2	5	2	5	2	0	0
1	3	6	3	5	2	1	1
2	1	7	4	8	5	-1	-1
2	2	8	5	8	5	0	0
2	3	9	6	8	5	1	1

- 对 $(\tilde{y}_{it}, \tilde{x}_{it})$ 做无截距回归，得 $\hat{\beta}_{FE} = \frac{\sum \tilde{y}_{it}\tilde{x}_{it}}{\sum \tilde{x}_{it}^2} = \frac{(-1)(-1)+1\cdot 1+(-1)(-1)+1\cdot 1}{(-1)^2+1^2+(-1)^2+1^2} = \frac{4}{4} = 1$。
- 结果解释：x 每增加 1 单位，y 平均增加 1 单位（个体内变化）。

3.4 一阶差分（First Difference）估计

- 对 t 和 $t-1$ 期做差分：

$$y_{it} - y_{i,t-1} = (\mathbf{x}_{it} - \mathbf{x}_{i,t-1})'\beta + (u_{it} - u_{i,t-1})$$

- α_i 被消除，仅使用 $T-1$ 个差分方程。
- 若 u_{it} 为 iid，则差分后的误差项 $u_{it} - u_{i,t-1}$ 存在一阶自相关（相关系数 -0.5）。
- 当 $T=2$ 时，FD 与 Within 等价；当 $T>2$ 且 u_{it} iid 时，Within 更有效。
- FD 对测量误差和序列相关可能更稳健。

数值示例：延续上例 $i=1$，$t=2$ 时 $y_{i2} - y_{i1} = 1$，$x_{i2} - x_{i1} = 1$；$t=3$ 时 $y_{i3} - y_{i2} = 1$，$x_{i3} - x_{i2} = 1$。回归得 $\hat{\beta} = 1$。

3.5 最小二乘虚拟变量（LSDV）估计

- 直接对 $y_{it} = \sum_{j=1}^{N} \alpha_j d_{j,it} + \mathbf{x}_{it}'\beta + u_{it}$ 做 OLS。
- 当 N 不太大时（如 $N < 1000$），可直接估计。
- 得到 $\hat{\alpha}_i$ 和 $\hat{\beta}$，且 $\hat{\beta}$ 与 Within 估计量完全相同。
- 标准误需要调整自由度（损失 N 个参数）。
- 在 Stata 中命令：‘xtreg y x, fe‘ 或 ‘reg y x i.id‘。
- 时间固定效应可加入 ‘i.year‘。

数值示例：$N = 3, T = 3$，生成个体哑元，回归 y_{it} 对 x_{it} 和哑元，得到 $\hat{\beta} = 0.85$，与 Within 结果一致。

4.1 随机效应模型设定与假设

- 模型：$y_{it} = \mathbf{x}_{it}'\beta + (\alpha_i + u_{it})$，其中 $\alpha_i \sim (0, \sigma_\alpha^2)$ 独立于 $\mathbf{x}_{it}$ 和 u_{it}。
- **关键假设**：α_i 与所有回归变量不相关（随机截距）。
- 复合误差项 $v_{it} = \alpha_i + u_{it}$，具有组内相关结构。
- 若假设成立，RE 估计量比 FE 更有效（利用了个体间变异）。
- 通常使用可行广义最小二乘（FGLS）估计。

数值示例：假设 $\sigma_\alpha^2 = 4$，$\sigma_u^2 = 1$，则同一体不同期的误差相关系数为 $\rho = 4/(4+1) = 0.8$，强正相关。

4.2 RE 的 GLS 估计与组内相关系数

- 复合误差的协方差矩阵：$\Omega = \sigma_u^2 I_T + \sigma_\alpha^2 \mathbf{1}_T \mathbf{1}_T'$。
- 组内相关系数（Intra-class correlation）：

$$\rho = \frac{\sigma_\alpha^2}{\sigma_\alpha^2 + \sigma_u^2}$$

- GLS 估计量：$\hat{\beta}_{RE} = (\mathbf{X}'\Omega^{-1}\mathbf{X})^{-1}\mathbf{X}'\Omega^{-1}\mathbf{y}$。
- 实践中用 FGLS：先估计 σ_α^2 和 σ_u^2（如通过 Within 和 Between 残差），再构造 $\hat{\Omega}$。
- RE 估计等价于对变量做部分离差变换：$y_{it} - \hat{\theta}\bar{y}_i$，其中 $\hat{\theta} = 1 - \sqrt{\sigma_u^2/(\sigma_u^2 + T\sigma_\alpha^2)}$。

数值示例：若 $T = 5$，$\hat{\sigma}_\alpha^2 = 2$，$\hat{\sigma}_u^2 = 1$，则 $\hat{\theta} = 1 - \sqrt{1/(1 + 5 \times 2)} \approx 0.69$。

4.3 固定效应与随机效应的核心区别

- **FE**：允许 α_i 与 $\mathbf{x}_{it}$ 任意相关；估计量仅使用组内变异；对遗漏时不变变量稳健；不能估计时不变变量的系数。
- **RE**：假设 α_i 与 $\mathbf{x}_{it}$ 独立；估计量使用组内和组间变异；可估计时不变变量系数；若假设错误则不一致。
- 选择原则：如果个体效应与解释变量相关，应使用 FE；若不相关，RE 更有效率。
- 实际中常假设相关，故 FE 更安全。

数值示例：研究工资与教育，若能力与教育相关，FE 消除能力偏误；若认为能力随机，RE 可同时估计教育年限和性别（时不变）的效应。

4.4 Hausman 检验的原理与操作

- 原假设 H_0：α_i 与 $\mathbf{x}_{it}$ 不相关（RE 有效）。
- 备择假设 H_1：相关（RE 不一致，FE 一致）。
- 检验统计量：

$$H = (\hat{\beta}_{FE} - \hat{\beta}_{RE})'[Var(\hat{\beta}_{FE}) - Var(\hat{\beta}_{RE})]^{-1}(\hat{\beta}_{FE} - \hat{\beta}_{RE}) \sim \chi^2(K)$$

- 若 H 大于临界值，拒绝 RE，采用 FE。
- 注意：在异方差或序列相关下需使用稳健形式。
- Stata 命令：‘hausman fe re‘。

数值示例：得到 $H = 25.3$，$K = 3$，$p < 0.001$，强烈拒绝 RE，采用固定效应。

5.1 动态面板模型与内生性问题

- 动态面板模型：$y_{it} = \gamma y_{i,t-1} + \mathbf{x}_{it}'\beta + \alpha_i + u_{it}$，$u_{it}$ iid。
- $y_{i,t-1}$ 与 α_i 相关（因为 α_i 影响所有时期），导致 OLS 和 FE 不一致。
- FE 组内变换产生 $y_{i,t-1} - \bar{y}_{i,-1}$ 仍与 $u_{it} - \bar{u}_i$ 相关（Nickell 偏误），当 T 小（如 $T = 2, 3$）时偏误严重。
- 需要工具变量或 GMM 方法。

数值示例：$T = 3$，真实 $\gamma = 0.4$，FE 估计可能得到 $\hat{\gamma} = 0.1$，向下偏误严重。

5.2 Anderson-Hsiao 工具变量估计

- Anderson 和 Hsiao (1981) 建议先对模型差分消除 α_i：

$$\Delta y_{it} = \gamma \Delta y_{i,t-1} + \Delta \mathbf{x}_{it}' \beta + \Delta u_{it}$$

- 用 $y_{i,t-2}$ 作为 $\Delta y_{i,t-1}$ 的工具，因为 $y_{i,t-2}$ 与 $\Delta u_{it} = u_{it} - u_{i,t-1}$ 不相关（无序列相关时）。
- 也可用 $\Delta y_{i,t-2}$ 作为工具。
- 两阶段最小二乘（2SLS）估计。
- 效率较低，但为后续 GMM 奠定了基础。

数值示例：$t = 3$ 时，用 y_{i1} 作为 $\Delta y_{i2} = y_{i2} - y_{i1}$ 的工具，进行 2SLS。

5.3 Arellano-Bond GMM 估计简介

- Arellano-Bond (1991) 提出差分 GMM，使用更多矩条件。
- 对差分方程：$\Delta y_{it} = \gamma \Delta y_{i,t-1} + \Delta \mathbf{x}_{it}' \beta + \Delta u_{it}$。
- 工具变量：对于 $t = 3$，用 y_{i1}；对于 $t = 4$，用 y_{i1}, y_{i2}；依此类推，所有滞后值。
- 若 $\mathbf{x}_{it}$ 内生，也可用其滞后值作工具。
- 需检验差分残差是否存在二阶序列相关（Arellano-Bond 检验）。
- Stata 命令：‘xtabond‘，‘xtabond2‘。

数值示例：$T = 5$，$N = 200$，差分 GMM 得到 $\hat{\gamma} = 0.35$，标准误 0.05。

5.4 应用实例：民主与经济增长

- Acemoglu et al. (2019, JPE) 使用 1960–2010 年跨国面板数据研究民主对人均 GDP 的因果效应。
- 模型：$y_{ct} = \gamma y_{c,t-1} + \beta Democracy_{ct} + \mathbf{x}'_{ct}\delta + \alpha_c + \lambda_t + u_{ct}$。
- 使用动态面板 GMM 和事件研究法。
- 主要发现：民主化显著提高人均 GDP（长期约 20%）。
- 稳健性：控制国家固定效应、时间趋势、初始发展水平等。
- 启示：面板数据方法在政策评估中的强大作用。

数值示例：民主化后 20 年，GDP 累计增长比非民主国家高 20%，$\beta \approx 0.01$（年增长率）。