时间序列分析导论

EC902

HenryY

华威大学

2026 年 4 月 8 日

目录

1. 时间序列导论与基本问题
2. 平稳性（Stationarity）与弱依赖性（Weak Dependence）
3. 平稳时间序列的例子与模型
4. 时间序列的数学工具与模型目标

1.1 时间序列的定义与核心特征

定义：

- 时间序列过程（Time Series Process）是一个按时间 t 索引的随机变量序列：

$$\{Y_1, Y_2, \ldots, Y_T\} = \{Y_t\}$$

- 也被称为随机过程（Stochastic Process）。
- 样本容量 T 表示观测到的时间周期数。

核心特征：

- **时间排序（Time Ordering）**：数据点的顺序至关重要。
- **序列依赖（Serial Dependence）**：当前值 Y_t 与过去值 $Y_{t-1}, Y_{t-2}, \ldots$ 相关。

数值示例：

- 若 Y_t 为 GDP，$Y_{2023} = 2.5\%$ 较高，则 Y_{2024} 也倾向于保持较高水平。

1.2 时间序列 vs. 横截面数据

横截面分析	时间序列分析
随机抽样假设	序列依赖
观测值相互独立（i.i.d.）	观测值不独立
数据顺序无关	数据顺序至关重要
推断基于标准 CLT	推断基于 FCLT

结论：

- 不能将经典的中心极限定理（CLT）直接应用于时间序列。
- 需要将其扩展到适用于随机过程的功能性中心极限定理（FCLT）。

1.3 时间序列的基本问题与解决思路

基本问题：

- 我们通常对联合分布 $F(Y_1, \ldots, Y_T)$ 的特征（均值、方差、协方差）感兴趣。
- 但我们只有一个样本路径（Sample Path）——一组特定的实现值。
- 只有一个观测值如何学习整个分布？

解决思路：

- 需要引入“**恒常性**”（**Constancy**）的概念。
- 最常见的假设是：时间序列是**平稳的**（**Stationary**）。
- 平稳性使得我们可以用历史数据的信息来推断未来或不同时间点的分布特征。

2.1 平稳性的概念与重要性

直观理解：

- 一个时间序列过程若其统计特性不随时间变化，则被认为是平稳的。
- “统计特性”通常指均值、方差和协方差。

重要性：

- 允许我们使用一个时间点的观测数据来估计总体的特征。
- 例如，若 $\mathbb{E}[Y_t] = \mu$（常数），我们可以用样本均值 $\bar{Y}$ 来估计 μ。

示例：

- 非平稳：股票价格（有上升趋势）。
- 弱平稳：股票日收益率（围绕 0 波动）。

2.2 协方差平稳（弱平稳）的数学定义

定义：一个随机过程 $\{Y_t\}$ 被称为弱（协方差）平稳的，如果满足以下三个条件：

1. **期望恒定**：
$$\mathbb{E}[Y_t] = \mu < \infty, \quad \forall t$$
2. **方差恒定**：
$$\mathbb{V}[Y_t] = \gamma_0 = \sigma^2 < \infty, \quad \forall t$$
3. **自协方差仅依赖于间隔** k：
$$\mathrm{Cov}(Y_t, Y_{t-k}) = \gamma_k, \quad \forall t, \forall k$$

数值示例：

- 若一个过程满足 $\mu = 5, \sigma^2 = 2, \gamma_1 = 0.5$，则这些值对所有 t 都相同。

2.3 自协方差（Autocovariance）的数学定义与性质

定义：对于协方差平稳过程，k 阶自协方差是 Y_t 与其 k 期滞后值 Y_{t-k} 的协方差。

$$\gamma_k = \mathrm{Cov}(Y_t, Y_{t-k}) = \mathbb{E}[(Y_t - \mu)(Y_{t-k} - \mu)]$$

性质：

- 它仅取决于时间距离 k，而非时间点 t。
- 衡量 Y_t 和 Y_{t-k} 之间的线性依赖方向。

重要推论：

- **方差是 0 阶自协方差**：

$$\gamma_0 = \mathrm{Cov}(Y_t, Y_t) = \mathbb{E}[(Y_t - \mu)^2] = \mathbb{V}[Y_t]$$

数值示例：

- 若 $\gamma_2 = 0.3$，说明相隔 2 期的观测值之间存在正相关关系。

2.4 自相关（Autocorrelation）与相关图（Correlogram）

定义： k 阶自相关系数 ρ_k 是标准化的自协方差。

$$\rho_k = \frac{\mathrm{Cov}(Y_t, Y_{t-k})}{\sqrt{\mathbb{V}[Y_t]\mathbb{V}[Y_{t-k}]}} = \frac{\gamma_k}{\gamma_0}$$

- 测度 Y_t 和 Y_{t-k} 之间线性关系的强度与方向。
- 取值范围： $-1 \leq \rho_k \leq 1$。

相关图（Correlogram）：

- 将 ρ_k 对 $k = 0, 1, 2, \ldots$ 绘制的图形。
- 是识别模型阶数的重要工具。

数值示例：

- 一个 AR(1) 模型，若 $\phi = 0.8$，则 $\rho_k = (0.8)^k$。相关图呈指数衰减。

2.5 弱平稳与严格平稳的关系

严格平稳（Strict Stationarity）：

- 要求整个联合分布随时间平移而不变。
- 即 $(Y_{t_1}, \ldots, Y_{t_n})$ 与 $(Y_{t_1+k}, \ldots, Y_{t_n+k})$ 具有相同的联合分布，对所有 n, k 成立。

关系：

- **严格平稳 + 二阶矩有限** $\Rightarrow$ **弱平稳**。
- **弱平稳** $\not\Rightarrow$ **严格平稳**。（弱平稳只限定前两阶矩，高阶矩可能随时间变化）

一个重要的特例：

- 如果过程是**联合正态分布（Jointly Normal）**的，则其分布完全由一阶矩和二阶矩决定。
- 在此情况下，**弱平稳** $\Rightarrow$ **严格平稳**。

3.1 高斯白噪声（Gaussian White Noise, GWN）

定义：

$$Y_t = \epsilon_t, \quad \epsilon_t \sim \text{i.i.d. } N(0, \sigma^2)$$

- $\mathbb{E}[Y_t] = 0$（期望恒定）
- $\mathbb{V}[Y_t] = \sigma^2$（方差恒定）
- $\gamma_k = 0, \quad \forall k \neq 0$（无自相关）

核心特征：

- 在时间序列的实现值中没有任何可预测的模式。
- 由于是正态分布，所以是严格平稳的。

数值示例：

- 从 $\epsilon_t \sim N(0, 1)$ 抽样：{0.5, -1.2, 0.8, -0.1, ...}。看到 0.5 后，无法预测下一个值是-1.2。

3.2 白噪声（White Noise, WN）的一般形式

定义：

$$Y_t = \epsilon_t, \quad \epsilon_t \sim \text{i.i.d.}/\text{独立?}\ (0, \sigma^2)$$

- 更一般地，$WN(0, \sigma^2)$ 只需要 ϵ_t 是**不相关（uncorrelated）**的，而不需要独立。
- $\mathbb{E}[Y_t] = 0$
- $\mathbb{V}[Y_t] = \sigma^2$
- $\gamma_j = 0, \quad \forall j \neq 0$

重要区别：

- 独立意味着更强的条件（$\Rightarrow$ 不相关）。
- 不相关不一定独立（例如，存在非线性依赖）。
- 白噪声（非 i.i.d.）可能不是严格平稳的。

数值示例：

- $\epsilon_t = \eta_t \cdot \eta_{t-1}$，其中 $\eta_t \sim$ i.i.d. $N(0, 1)$。ϵ_t 不相关但非独立。

3.3 自回归（AR）模型

定义： p 阶自回归过程 AR(p)：

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \epsilon_t$$

- $\epsilon_t \sim$ i.i.d. $(0, \sigma^2)$
- $\phi_1, \ldots, \phi_p$ 是待估参数。
- 当前值 y_t 是它自身过去值的线性函数加上一个随机冲击。

最简单的例子：AR(1) 模型

$$y_t = \phi y_{t-1} + \epsilon_t$$

数值示例：

- 设 $\phi = 0.6, \epsilon_t = 1, y_{t-1} = 5$，则 $y_t = 0.6 \times 5 + 1 = 4$。

3.4 移动平均（MA）模型

定义： q 阶移动平均过程 MA(q)：

$$y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q}$$

- $\epsilon_t \sim$ i.i.d. $(0, \sigma^2)$
- $\theta_1, \ldots, \theta_q$ 是待估参数。
- 当前值 y_t 是当前和过去 q 期随机冲击的加权平均。

最简单的例子：MA(1) 模型

$$y_t = \epsilon_t + \theta \epsilon_{t-1}$$

数值示例：

- 设 $\theta = 0.8, \epsilon_t = 2, \epsilon_{t-1} = 1$，则 $y_t = 2 + 0.8 \times 1 = 2.8$。

3.5 自回归移动平均（ARMA）模型

定义： ARMA(p, q) 模型结合了 AR 和 MA 部分。

$$y_t = \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$$

- $\epsilon_t \sim$ i.i.d. $(0, \sigma^2)$
- 使用较少的参数就能捕捉更复杂的序列依赖模式。

一个简单例子：ARMA(1,1) 模型

$$y_t = \phi y_{t-1} + \epsilon_t + \theta \epsilon_{t-1}$$

数值示例：

- 设 $\phi = 0.5, \theta = 0.3, y_{t-1} = 4, \epsilon_t = 1, \epsilon_{t-1} = 0.5$。
- 则 $y_t = (0.5 \times 4) + 1 + (0.3 \times 0.5) = 2 + 1 + 0.15 = 3.15$。

3.6 非零均值 ARMA 模型的处理

问题：上述模型都是均值为 0 的。如何处理非零均值 $E[x_t] = \mu \neq 0$？**解决方案**：

- 定义**去均值（de-meaned）**变量：$y_t = x_t - \mu$。
- 对 y_t 建立 ARMA 模型。

以 AR(1) 为例：

$$
\begin{aligned}
(x_t - \mu) &= \phi(x_{t-1} - \mu) + \epsilon_t \\
\Rightarrow x_t &= (1-\phi)\mu + \phi x_{t-1} + \epsilon_t
\end{aligned}
$$

数值示例：

- 设 $\mu = 10, \phi = 0.7, x_{t-1} = 12$。
- 则常数项 $c = (1 - 0.7) \times 10 = 3$。
- $x_t = 3 + 0.7 \times 12 + \epsilon_t = 11.4 + \epsilon_t$。

4.1 滞后算子（Lag Operator）的定义与运算

定义：滞后算子 L 将时间索引向后移动一期：

$$Ly_t = y_{t-1}$$

运算规则：

- **多次滞后**：$L^2 y_t = L(Ly_t) = Ly_{t-1} = y_{t-2}$，一般地 $L^j y_t = y_{t-j}$。
- **前向移动**：$L^{-j} y_t = y_{t+j}$。
- **差分算子**：$\Delta y_t = y_t - y_{t-1} = (1-L)y_t$。
- **二阶差分**：$\Delta^2 y_t = (1-L)^2 y_t = y_t - 2y_{t-1} + y_{t-2}$。

数值示例：

- 若 $y_t = \{5, 8, 6, 3\}$，则 $Ly_t = \{\text{缺失}, 5, 8, 6\}$。
- $\Delta y_t = \{\text{缺失}, 3, -2, -3\}$。

4.2 滞后多项式（Lag Polynomial）与模型重构

定义：一个滞后多项式是 L 的线性组合。

$$a(L) = a_0 + a_1 L + a_2 L^2 + \cdots + a_p L^p$$

模型重写：

- **AR(p) 模型**： $\phi(L) y_t = \epsilon_t$，其中 $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p$。
- **MA(q) 模型**： $y_t = \theta(L)\epsilon_t$，其中 $\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q$。
- **ARMA(p,q) 模型**： $\phi(L) y_t = \theta(L)\epsilon_t$。

数值示例 (AR(1)):

- $y_t = 0.6 y_{t-1} + \epsilon_t$ 可以写成 $(1 - 0.6L) y_t = \epsilon_t$。

4.3 单变量时间序列分析的核心目标

核心任务：

1. **分析（Analysis）**：理解序列自身的动态结构。
   - 识别序列依赖的模式。
   - 估计模型参数（ϕ, θ）。
   - 检验模型的充分性（如残差是否为白噪声）。
2. **预测（Forecasting）**：基于过去和当前信息预测未来值。

模型输入：

- 序列自身的过去模式。
- 一个随机误差项（当前和过去）。
- **不包含外生变量**。

示例：

- 使用过去 4 个季度的 GDP 数据来预测下一个季度的 GDP。

4.4 课后练习与课程总结

练习：写出以下过程的数学表达式。

1. AR(2) 过程
2. AR(4) 过程
3. MA(2) 过程
4. MA(3) 过程
5. ARMA(2, 1) 过程
6. ARMA(1, 2) 过程

课程总结：

- **平稳性**是时间序列分析的核心假设，使得统计推断成为可能。
- **ARMA 模型**族是描述平稳时间序列动态依赖关系的强大工具。
- **滞后算子**提供了简洁的数学表达形式。
- 本讲为后续更深入的**估计**、**诊断和预测**奠定了理论基础。